

Prof. Dr. Peer Küppers

DSCB140
Datenbanken und Datenkunde I

VL1 – Einführung &
Datenbankgrundlagen


Kontakt & Administratives

- Prof. Dr. Peer Küppers
 - E-Mail: peer.kueppers@h-ka.de
- Bei Fragen
 - Nutzen Sie bitte Mattermost für die Kommunikation mit mir (Direktnachrichten)

Kontakt & Administratives

■ Datenbank-Client

- Bitte installieren Sie auf Ihrem Rechner das Programm DBeaver.
 - <https://dbeaver.io/>
- Dieses ist unser Datenbank-Client – damit steuern wir also die Datenbank und können Data Science mit dieser betreiben.



- Übungsblätter
 - Aktuelle Planung (Änderungen vorbehalten): 6 zu bearbeitende Übungsblätter
 - Die Übungsblätter werden in **Vierergruppen** bearbeitet
 - Bitte formen Sie die **Gruppen in ILIAS (Übungsgruppen)** und bestimmen Sie einen **Gruppenverantwortlichen** (für den Upload des Codes, dazu später mehr)
 - Details: siehe Vorlesungsplanung in ILIAS
- Präsenzübungen: Lösungsvorschläge und Diskussion
 - In den Präsenzübungen behandeln wir die Übungsblätter und allgemeine Fragen.
 - Darüber hinaus werden wir in „Saalübungen“ gemeinsam zusätzliche Übungsaufgaben bearbeiten.
- Bitte tragen Sie sich in ILIAS in eine Gruppe ein.

■ Bonuspunkte (Änderungen vorbehalten)

- Durch die Bearbeitung der Übungsblätter können Sie Bonuspunkte für die Klausur sammeln. Sie können **maximal 10% der Klausurpunkte** erreichen.
 - Bsp.: Klausur mit 90 Punkten → maximal 9 Bonuspunkte möglich.
 - Ohne Bonuspunkte ist dennoch eine 1,0 in der Klausur erreichbar!
 - Mehr als 1,0 ist nicht möglich.
- Punkteermittlung:
Es werden die Punkte aller Abgaben **summiert und prozentual in Bonuspunkte umgerechnet**
 - Beispiel: Alle 6 Übungsblätter ergeben in Summe 600 Punkte.
 - Sie erreichen insgesamt 450 Punkte.
 - Sie erhalten $450/600 = 75\%$ der maximal möglichen Bonuspunkte.
 - Das entspricht $7,5\%$ der maximalen Klausurpunkte = 6,75 Bonuspunkte (bei 90-minütiger Klausur mit 90 Punkten)




- Vorlesungsunterlagen
 - In der Regel vor der Veranstaltung bereitgestellt.
 - Kleinere Übungen finden sich in den Vorlesungsfolien.
 - Weitere Übungen unter <https://pkuep.github.io/hska-140-db/> (machen wir gemeinsam).
- Es wird zusätzlich Übungsblätter geben. Weitere Infos dazu in den Übungen. Vorab: Sie können damit Bonuspunkte für die Klausur sammeln.
- Online-Whiteboard: siehe ILIAS
- Cloud-Umgebung (Google Cloud Platform) – richten wir später ein
- Datenbankmanagementsystem (RDBMS) MySQL
 - Richten wir in der ersten Übung ein.
 - Später werden wir auch auf das Cloud-Angebot zurückgreifen.




- Kemper, Alfons; Eickler, André (2015): Datenbanksysteme. Eine Einführung. 10., aktualisierte und erweiterte Auflage. Berlin, Boston: De Gruyter Oldenbourg (De Gruyter Oldenbourg Studium).
 - Begleitende Website: <https://db.in.tum.de/teaching/bookDBMSeinf/index.shtml?lang=de>
 - Auf diesen Materialien basieren einige Teile der Veranstaltung.
- Kemper, Alfons; Wimmer, Martin (2012): Übungsbuch Datenbanksysteme. 3., aktualisierte und erweiterte Auflage. München: Oldenbourg.
- Elmasri, Ramez; Navathe, Shamkant B. (2017): Fundamentals of database systems. Seventh edition. Pearson.
 - 6. Auflage (engl.) verfügbar unter <http://iips.icci.edu.ig/images/exam/databases-ramaz.pdf>.
 - Deutsche Auflage: Elmasri, Ramez A.; Navathe, Shamkant B.; Shafir, Angelika (2011): Grundlagen von Datenbanksystemen. München: Pearson Studium (IT - Informatik).
- Vornberger, Oliver; Haldenwang, Nils (2015): Datenbanksysteme. Vorlesungsskript. Universität Osnabrück, Osnabrück. Institut für Informatik.
 - Für die Veranstaltung nicht vollständig relevante Kapitel: 4, 5, 10, 11, 15, 16, 18
 - Online verfügbar unter <http://www-lehre.inf.uos.de/~dbs/2015/PDF/dbs-2015-media2mult.pdf>.

- <https://pk-bigdata.appspot.com>
- Simulierter Webshop
- Zusammenhang zu Datenbanken?




Anwendungsfall

■ Zusammenhang zu Datenbanken



Anwendungsfall

■ Zusammenhang zu Data Science



Unzählige
Anwendungen
und Prozesse sowie
externe Datenquellen




Datenhaltung
kann sehr vielfältig sein
(zahlreiche Quellen,
unterschiedliche Technologien,
Programmiermodelle, ...)

Sum of Product-Group-Sales per age and weekday



Sum of Sales per date and region



Datenbanken
sind oft die
Basis für
Data Science und
Machine Learning

Wir nutzen eine online Beispiel-Datenbank zum Einstieg:

<https://datalemur.com/questions/completed-trades>


Welche Arten von Daten sehen wir hier?

Welche Gedanken mussten sich die „Designer“ dieser Datenbank machen?

Welche Auswertungen könnten interessant sein?


Datenbanken und Data Science

Ziel von Analytics: Optimale Entscheidungen (möglichst automatisiert) ermitteln



Lernziele

- **Grundlegende Konzepte und Methoden der Datenkunde und -haltung wiedergeben, anwenden und in RDBMS umsetzen können**



- **Voraussetzungen & Vorkenntnisse: keine** (außer Interesse an Data Science!)

■ Modulhandbuch

Datenbanken: Die Studierenden haben die grundlegenden Modelle, Konzepte, Architekturen und Implementierungen von Datenbanken und Datenbanksystemen verstanden. Sie verstehen die Grundlagen relationaler Datenmodellierung und beherrschen deren Umsetzung insbesondere in SQL und den dazu zugehörigen gängigen relationalen Datenbankmanagementsystemen (RDBMS).

- Die Studierenden beherrschen die wesentlichen Konzepte und Methoden relationaler Datenmodellierung: Entity/Relationship-Modelle, relationale Datenmodelle und Anfragesprachen, Tabellen und Normalformen
- Die Studierenden kennen die grundlegende abstrakte Funktionsweise relationaler Anfragesprachen.
- Die Studierenden verstehen und beherrschen die Konzepte und Hauptmerkmale der Abfragesprache SQL und deren Teile DML, DDL, DCL, und deren Umsetzung in relationalen DBMS.
- Die Studierenden haben die Fähigkeit, ein gängiges RDBMS (Oracle, DB2, PostgreSQL, MSSQL, MySQL, ...) im Rahmen des Datenbankentwurfs und der Anfrageverarbeitung zu benutzen. Sie sind in der Lage, auch komplexe SQL-Abfragen an relationale Datenbanken zu formulieren und zu evaluieren.
- Die Studierenden kennen und verstehen die Konzeption, Architektur und Einsatzgebiete von Datenbanksystemen und datenbankgestützter Anwendungssysteme.
- Die Studierenden verstehen die Konzepte und Hauptmerkmale von Transaktionen und deren Umsetzung in Datenbankmanagementsystemen.

- **Konzeptionelle Modellierung**
- **Relationales Modell**
- **SQL – die Datenbanksprache**
- **RDBMS Verwendung und Einsatz**
- **Komplexe Funktionen von Datenbanken (Auswertungen, Aggregationen, Transaktionen etc.)**


■ Modulhandbuch

Datenkunde: Die Studierenden verstehen grundlegende Charakteristika von Daten und kennen zentrale Aspekte und Herausforderungen beim maschinellen Umgang mit Daten im Allgemeinen und in der Data Science im Besonderen.


- Die Studierenden kennen grundlegende Begriffe und Konzepte im Bezug auf Daten und Datenverarbeitung: Daten, Information, Zeichen, Symbole, Syntax, Semantik, Kodierung, Datenhaltung, Strukturierung, Informationsgehalt
 - Die Studierenden entwickeln ein grundlegendes Verständnis für den Ursprung und die Funktion von Daten: Messungen, Beobachtungen, Kommunikationsvorgänge, Transaktionen, Betriebliche Daten, usw.
 - Die Studierenden entwickeln ein Verständnis für grundlegende Kategorien von Daten: Strukturierte / Semistrukturierte / Unstrukturierte Daten, Transiente / Persistente Daten, Originäre vs. Abgeleitete Daten, usw.
 - Die Studierenden kennen Grundkonzepte der Datenstrukturierung und -repräsentation: Text/Bild/Tabellenformate, Binärformate, JSON, ...
 - Die Studierenden kennen Grundkonzepte der Datenkodierung und -formatierung: ASCII, UTF-8, Datei-Header
 - Die Studierenden kennen Grundkonzepte der Datenspeicherung und -haltung: Speicherung auf Flüchtigen/Nicht-flüchtigen Medien, Dateien, Datenbanken, Verteilte Speichermedien, ...
 - Die Studierenden kennen Grundkonzepte der Verarbeitung von Daten: CRUD, Netzwerkkommunikation, Dateiaustausch, usw.
 - Die Studierenden kennen grundlegende (gesellschaftliche) Herausforderungen beim Umgang mit Daten: Datenschutz, Datenherkunft, Data Governance, ...
- **Begrifflichkeiten und theoretische Grundlagen der Datenhaltung**
 - **Einordnung von Datenhaltungsoptionen und Datenquellen**
 - **Datenkodierung**
 - **Persistenz / Nicht-Persistenz von Daten**
 - **Data Governance**



A Datenbankgrundlagen



B Konzeptionelle Modellierung




C Logische Modellierung & Normalisierung

MID	Name	Adresse	Gehalt
1234	Müller	Hofstraße 7	23.000 €
1235	Meyer	Hauptstraße 13b	45.678 €
1236	Schmidt	Kurze Straße 1	55.555 €
1237	Heinze	Neue Straße 34	44.333 €
1238	Mustermann	Musterstraße 8	80.000 €
1239	...	...	...


D Structured Query Language (SQL)

```
-- filter your columns
SELECT col1, col2, col3, ... FROM table1
-- filter the rows
WHERE col4 = 1 AND col5 = 2
-- aggregate the data
GROUP by ...
-- limit aggregated data
HAVING count(*) > 1
-- order of the results
ORDER BY col2
```

E Analytics mit SQL



F Weitere Formen und Grundlagen der Datenhaltung



Agenda

- **Anwendungsfall & Lernziele**
- ☐ **Übung: Grenzen der dateibasierten Speicherung von Daten**
- ☐ **Datenbankgrundlagen und Definitionen**
- ☐ **Zusammenfassung & Ausblick**

Übung “Dateibasierte Speicherung”



Wir arbeiten vorerst nur lokal!

- Übung (<https://pkuep.github.io/hska-140-db>)
 - Wir möchten nun lernen, wie eine Datenhaltung – wenn Sie **unstrukturiert** verfolgt wird – zu **Herausforderungen** führen kann.
 - Dazu betrachten wir ein Beispiel: „Lagerbestandsverwaltung“.
 - Wir nutzen hierzu eine moderne Umgebung: in der **Cloud** werden Sie einen Rechner (eine sogenannte **virtuelle Maschine**) starten, in der Sie auf eine Programmierumgebung zugreifen (Programmiersprache **Python**, Umgebung „**Jupyter Notebooks**“).
 - Python und Jupyter Notebooks: sehr weit verbreitete **Data Science-Umgebung!**
 - Wir nutzen diese Umgebung, um Daten zu speichern und abzurufen.
 - Wichtig: es wird (noch) nicht erwartet, dass Sie Python programmieren können. Dies sind zunächst nur einfache Beispiele!

DSCB140 - Datenbanken und Datenkunde

Einführung


➡ Herausforderungen dateibasierter Speicherung und erster Datenbankkontakt

Übung “Dateibasierte Speicherung”




- Diskussion

Anwendungsbeispiel



- Wir möchten einen Web-Shop eröffnen.
- Die selbst programmierte Anwendung muss Daten speichern:
Artikel, Kunden, Aufträge usw.
 - Wir fangen bei der Programmierung so an, dass die Daten in einzelnen Dateien im Dateisystem abgelegt werden, also:
 - eine Datei für Artikel,
 - eine Datei für Kunden,
 - eine Datei für Bestellungen usw.
- Welche Probleme können bei dieser Lösung auftreten?



■ Beispielhafte Probleme

- Herr Müller speichert die Datei „Artikel“ an einem anderen Ort als Herr Schmidt.
- Werden beide Dateien nicht laufend synchronisiert, dann laufen die Daten „auseinander“ und sind nicht mehr **konsistent**.
- Wird ein Kunde in der Kundendatei gelöscht, dann ist nicht sichergestellt, dass dieser auch wirklich gelöscht werden durfte (bspw. bei noch offenen Aufträgen).
- Sollte das „Datenformat“ geändert werden, können u. U. andere Programme die Daten nicht mehr korrekt „nutzen“.
 - Beispiel: Herr Müller nutzt eine weitere Spalte „Telefonnummer“.
- Wenn zwei Mitarbeiter die Datei gleichzeitig bearbeiten wollen, besteht die Gefahr des gegenseitigen Überschreibens von Daten.
 - Beispiel: Excel sperrt den Zugriff, wenn die Datei auf einem Netzwerklaufwerk liegt.
- Unterschiedliche „Sichten“ auf Daten sind schwer abzubilden
 - Z. B. Marketing vs. Personalabteilung: nicht jeder darf alles sehen, z. B. Gehaltsdaten

Datenbanken als Lösung


- Das Problem wurde schon vor langer Zeit erkannt:
 - *“Future users of large data banks must be **protected from having to know how the data is organized in the machine** (the internal representation). ... Activities of users at terminals and most application programs should remain unaffected when the **internal representation of data is changed** and even when some aspects of the external representation are changed. Changes in data representation will often be needed as a result of changes in query, update, and report traffic and natural growth in the types of stored information.”* – E.F. Codd

Quelle: E. F. Codd: A Relational Model of Data for Large Shared Data Banks, Communications of the ACM Juni 1970


- Es muss gelten: keine Kenntnis der Anwendung über die interne Daten-Repräsentation notwendig!
- Datenbankmanagementsysteme (DBMS) als Lösung

DBMS als Lösung

Übergang von isolierten Dateien:



Zu einer zentralen Datenbasis:



- In einer Bibliothek werden die zu verleihenden Bücher in einer einzigen Datei verwaltet. Die folgende Tabelle zeigt, wie die Daten gespeichert werden:


ISBN	Autor	Titel	Verlag
3834812226	H. Neuendorf	Java-Grundkurs für Wirtschaftsinformatiker	Vieweg+Teubner
3834813826	G. Blakowski	Datenbanken für Wirtschaftsinformatiker	Vieweg+Teubner
3834812226	H. Neuendorf	Java-Grundkurs für Wirtschaftsinformatiker	Vieweg+Teubner
3834813816	G. Brosius	Datenbanken für Wirtschaftsinformatiker	Teubner+Vieweg
3834813826	S. Cordts	Datenbanken für Wirtschaftsinformatiker	Springer Verlag
3540372172	G. Fandel	Produktionsmanagement	Springer Verlag

- In der Dateistruktur sind mehrere Entwurfsfehler enthalten, die zu Problemen bei der Speicherung geführt haben. Um welche Probleme handelt es sich und wie könnten diese gelöst werden?


Probleme bei isolierter Datenhaltung

- **Redundanz:** Dieselben Informationen werden mehrfach gespeichert.
- **Inkonsistenz:** Unterschiedliche Versionen derselben Informationen
- **Integrität:** Einhaltung von Integritätsbedingungen fällt schwer.
 - Beispiel: Artikel in Bestellungen müssen im Artikelstamm enthalten sein!
- **Verknüpfungseinschränkung:** Logisch „verwandte“ Daten sind schwer zu verknüpfen, wenn sie in isolierten Dateien liegen.
- **Mehrbenutzerprobleme:** Das gleichzeitige Bearbeiten derselben Datei kann zu Anomalien führen.
- **Verlust von Daten:** Begrenzt auf komplettes Backup einzelner Dateien
 - Kein spezieller „Recovery-Mechanismus“ bei Konflikten einzelner Datenelemente
- **Sicherheitsprobleme:** Zugriffsrechte müssen aufwändig manuell implementiert werden.
- **Hohe Entwicklungskosten:** Für jedes Anwendungsprogramm müssen die Fragen zur Dateiverwaltung erneut gelöst werden.

Weiterführendes Material



- Video zur Motivation / Notwendigkeit von Datenbanksystemen
https://www.youtube.com/watch?v=l0z3OqCII_E



13.04 Warum Datenbanksysteme?

Jens Dittrich • 15.000 Aufrufe • vor 4 Jahren

Komplette Liste der Videos und zusätzliches Material auf <http://datenbankenlernen.de> Informatik, Uni Saarland:


Agenda

- ☐ Anwendungsfall & Lernziele
- ☐ Übung: Grenzen der dateibasierten Speicherung von Daten
- ☒ Datenbankgrundlagen und Definitionen
- ☐ Zusammenfassung & Ausblick


Themenüberblick



A Datenbankgrundlagen



B Konzeptionelle Modellierung




C Logische Modellierung & Normalisierung

MID	Name	Adresse	Gehalt
1234	Müller	Hofstraße 7	23.000 €
1235	Meyer	Hauptstraße 13b	45.678 €
1236	Schmidt	Kurze Straße 1	55.555 €
1237	Heinze	Neue Straße 34	44.333 €
1238	Mustermann	Musterstraße 8	80.000 €
1239	...	...	...

D Structured Query Language (SQL)

- filter your columns
SELECT col1, col2, col3, ... **FROM** table1
- filter the rows
WHERE col4 = 1 **AND** col5 = 2
- aggregate the data
GROUP by ...
- limit aggregated data
HAVING count(*) > 1
- order of the results
ORDER BY col2

E Analytics mit SQL



F Weitere Formen und Grundlagen der Datenhaltung



Terminologie im Kontext von DBMS


■ Daten

- *„Zum Zweck der Verarbeitung zusammengefasste Zeichen, die aufgrund bekannter oder unterstellter Abmachungen Informationen (d.h. Angaben über Sachverhalte und Vorgänge) darstellen.“* (Gabler Wirtschaftslexikon)
- Bekannte **Tatsachen** (bspw. Verkauf eines Artikels an einen Kunden) über die **interessierende Domäne** (bspw. Online-Shop)

■ Datenbank

- *„Eine Datenbank ist eine integrierte Ansammlung von Daten, die [ggf.] unterschiedlichen Anwendungen als gemeinsame Datenbasis dient.“* (Enzyklopädie der Wirtschaftsinformatik)
- **Strukturierte Sammlung von Daten** über eine Domäne (bspw. Online-Shop), d.h.
 - logisch zusammenhängend
 - systematisch aufgezeichnet
 - gespeichert und gepflegt
 - zweckmäßig (bspw. für verschiedene Anwender)

Terminologie im Kontext von DBMS



■ Datenbankmanagementsystem (DBMS)


- Software zum Erstellen und Pflegen von Datenbanken
- **Generisch**, d.h. unabhängig von einem bestimmten Anwendungsgebiet.
- Beispiele: MySQL, PostgreSQL, neo4j, CouchDB, ...
- Anforderungen an DBMS
 - Sicher (Systemausfälle, Nutzerberechtigungen, ...)
 - Effizient (Antwortzeiten, reibungsloser Mehrbenutzerbetrieb, ...)
 - Zweckmäßig (auf den Anwendungsfall ausgerichtet, bspw. Abfragesprache für Data Scientists)
 - Ggf. Sicherstellung der Konsistenz und Integrität (insbesondere relationale DBMS)
 - Einhalten von Standards (bspw. Abfragesprache SQL bei relationalen DBMS)

■ Datenbanksystem

- System zur effizienten, widerspruchsfreien und dauerhaften Speicherung sowie bedarfsgerechten Bereitstellung von Daten in einem **konkreten** Anwendungskontext
- Zwei Teile:
 - Verwaltungssoftware (DBMS)
 - Menge der zu verwaltenden Daten (Datenbank im engeren Sinn), auch Datenbasis genannt

DBMS und Datenbanksysteme


- DBMS können mehr als eine Datenbank enthalten:



Neben den eigentlichen Datenbanken enthält das DBMS auch eine Datenbasis zum Speichern von **Metadaten** ("Daten über Daten"), wie Informationen über die Datenstruktur, Zugriffsrechte, etc.

Datenabstraktion nach der ANSI/SPARC-Architektur

■ Abstraktionsebenen




ANSI = American National Standards Institute

SPARC = Standards Planning and Requirements Committee

Datenunabhängigkeit


Physische Datenunabhängigkeit

- Bei Änderung der internen Ebene keine Änderung der konzeptionellen Ebene
 - In relationalen DBMS ohne Weiteres verfügbar



Logische Datenunabhängigkeit


- Bei Änderungen der konzeptionellen Ebene keine Änderung der externen Ebene notwendig.
 - Ziel: Anwendungen gegen Änderungen des Datenbankschemas „immun“
 - Schwierig zu erreichen (Sichten als Ansatz), beschränkt auf einfache Änderungen



Typische Komponenten eines DBMS

**Zusammen
Abbildung der
drei Ebenen**
(externe
Schemata,
konzeptionelles
Schema, internes
Schema)


Dazu später mehr!




DDL: Data Definition Language
DML: Data Manipulation Language

Quelle: Vornberger 2015

Weiterführendes Material



- Video zur physischen und logischen Unabhängigkeit
<https://www.youtube.com/watch?v=Flb3SeEcqGc>



13.06 Physische und Logische Datenunabhängigkeit

Jens Dittrich • 10.000 Aufrufe • vor 4 Jahren

Komplette Liste der Videos und zusätzliches Material auf <http://datenbankenlernen.de> Informatik, Uni Saarland:

Agenda

- ☐ Anwendungsfall & Lernziele
- ☐ Übung: Grenzen der dateibasierten Speicherung von Daten
- ☐ Datenbankgrundlagen und Definitionen
- ☒ Zusammenfassung & Ausblick

Zusammenfassung und Ausblick



- Sie haben die Herausforderungen der Datenhaltung anhand eines konkreten Beispiels „Lagerverwaltung“ in der Cloud erlebt.
- Wir haben uns mit den terminologischen Grundlagen von Datenbanken und Datenbanksystemen vertraut gemacht. Sie kennen die Begrifflichkeiten der Datenunabhängigkeit sowie die ANSI/SPARC-Architektur.
- Sie sollten nun ein Grundverständnis für die Notwendigkeit von Datenbanken sowie den Anforderungen an Datenbanken haben.
- In den folgenden Veranstaltungen werden wir uns mit den Zusammenhängen der Datenmodellierung befassen und damit beginnen Daten konzeptionell, d.h. ohne starken Technikbezug, zu modellieren.

Vielen Dank für Ihre Aufmerksamkeit!

